

Dokumentacja Specyfikacji Wymagań (SRS)

Projekt: Analiza opinii pracowników Green Café Nero

Data: 01.06.2026

Autorzy: Aleksandra Sikorska, Izabela Sprysak

1. Wprowadzenie

Niniejszy dokument przedstawia szczegółową specyfikację projektu realizującego analizę tekstu opinii pracowników przy użyciu języka R. Projekt został przygotowany w celu przeprowadzenia eksploracyjnej analizy danych tekstowych (Text Mining) oraz identyfikacji najczęściej pojawiających się zagadnień, problemów i pozytywnych aspektów wskazywanych przez pracowników w opiniach dotyczących miejsca pracy. Analiza wykorzystuje tworzenie korpusów tekstowych, czyszczenie i normalizację tekstu, tokenizację, stemming, usuwanie stopwords, analizę częstości występowania słów, analizę współwystępowania wyrażzeń, tworzenie macierzy Term Document Matrix, modelowanie tematów oraz wizualizację danych tekstowych przy pomocy chmur słów. Wyniki analizy prezentowane są w postaci chmur słów, graficznych wykresów asocjacji oraz zestawień słów kluczowych.

2. Cele systemu

- Wczytanie danych: import opinii z pliku .csv
- Segmentacja analizy: rozdzielenie tekstu na trzy osobne ścieżki
- Czyszczenie tekstu: usunięcie URL, tagów, znaków specjalnych, stemming oraz normalizacja językowa
- Analiza częstości: wyłonienie najpopularniejszych terminów dla każdego z segmentów opinii
- Badanie asocjacji: wykrywanie statystycznych powiązań między słowami
- Wizualizacja: generowanie chmur słów oraz wykresów obrazujących trendy w opiniach

3. Wymagania funkcjonalne

- Umożliwia wczytywanie danych tekstowych z lokalnego pliku CSV przy zachowaniu poprawnej obsługi kodowania UTF-8
- Tworzy oddzielne korpusy tekstowe dla każdej części opinii
- Usuwa adresy URL, symbole specjalne, tabulatory, znaki nowej linii, liczby, interpunkcję oraz inne zbędne elementy techniczne mogące zakłócać analizę
- Zamienia tekst na małe litery, a słowa pozbawia wartości informacyjnej przy pomocy mechanizmu stopwords

- Przeprowadza stemming tekstu
- Tworzy macierze Term Document Matrix dla każdego korpusu tekstowego
- Oblicza liczbę wystąpień poszczególnych słów i przedstawia wyniki w postaci uporządkowanej listy najczęściej występujących terminów
- Generuje chmurę słów przedstawiających najczęściej pojawiające się wyrażenia.
- Umożliwiać analizę asocjacji pomiędzy słowami przy pomocy funkcji ``findAssocs()`` oraz generuje na ich podstawie wykresy asocjacji
- Realizuje modelowanie tematów

4. Wymagania niefunkcjonalne

- Wydajność
 - system powinien umożliwiać analizę zbiorów danych zawierających od kilkuset do kilku tysięcy opinii w czasie nieprzekraczającym kilku minut
- Niezawodność
 - system powinien poprawnie obsługiwać: brakujące dane, puste pola tekstowe, błędne znaki, nietypowe formatowanie, dane zawierające linki i symbole specjalne
- Użyteczność
 - system powinien, generować czytelne wizualizacje, umożliwiać łatwą interpretację wyników, być prosty w użyciu w środowisku RStudio, posiadać przejrzysty i modularny kod
- Łatwość utrzymania
 - kod powinien być podzielony na logiczne sekcje, wykorzystywać funkcje pomocnicze, zawierać komentarze wyjaśniające działanie, umożliwiać dalszą rozbudowę projektu

5. Interfejsy i Dane

- Wejście:
 - plik `reviews.csv` zawierający kolumny tekstowe
- Wyjście:
 - ramki danych z rankingiem słów
 - wizualne chmury słów
 - graficzne wykresy asocjacji
 - wyniki modelowania tematów
 - wyniki asocjacji wyświetlane w konsoli

6. Słownictwo projektowe

- Korpus (Corpus): zbiór dokumentów tekstowych przygotowanych do analizy
- TDM (Term-Document Matrix): macierz, w której wiersze to słowa, a kolumny to dokumenty (opinie)
- Stemming: proces redukcji odmienionych (lub pochodnych) słów do ich formy podstawowej lub rdzenia

- Asocjacje: miara korelacji między słowami, wskazuje, jak często dwa słowa występują blisko siebie w danym kontekście
- Modelowanie tematów (Topic Modeling): technika statystyczna służąca do odkrywania tematów występujących w zbiorze dokumentów
- Wordcloud: wizualizacja, w której rozmiar słowa jest proporcjonalny do jego częstości w tekście

7. Przypadki użycia i scenariusze (User Stories)

Scenariusz 1: Identyfikacja przyczyn niezadowolenia

Jako: Specjalista HR

Chcę: Przeanalizować chmurę słów i asocjacje dla kolumny worst_things

Aby: Dowiedzieć się, dlaczego pracownicy skarżą się na przerwy (breaks) i czy ma to związek z brakiem płatności (unpaid) czy ich długością (short).

Scenariusz 2: Analiza benefitów i kultury pracy

Jako: Employer Branding Specialist

Chcę: Zobaczyć najczęściej pojawiające się słowa w pozytywnych opiniach

Aby: Wykorzystać informacje o "darmowej kawie" lub "świetnym zespole" w kampanii rekrutacyjnej.

Scenariusz 3: Badanie roli kadry zarządzającej

Jako: Właściciel firmy

Chcę: Sprawdzić asocjacje dla słowa "manager" w całym zbiorze opinii.

Aby: Zrozumieć, czy kadra kierownicza jest kojarzona ze wsparciem zespołu, czy raczej z problemami organizacyjnymi.